

# Получение простой выборки на выходе слоя нейронной сети\*

Панченко С. К.<sup>1</sup>, Гадаев Т. Т.<sup>1</sup>, Грабовой А. В.<sup>1</sup>, Стрижов В. В.

panchenko.sk@phystech.edu

<sup>1</sup>Московский Физико-Технический Институт

Границы применимости многочисленных методов математической статистики, применяемых в анализе, обуславливаются знанием вероятностной природы данных, которая, как правило, заранее неизвестна. В данной статье предлагается объединение целого комплекса статистических критериев в универсальный инструмент исследования распределений, порождающих выборки. Также предлагается алгоритм усовершенствования нейронной сети на основе анализа выборки, полученной на выходе её предпоследнего слоя, с помощью предложенного инструмента.

**Ключевые слова:** *тестирование гипотез, полносвязная нейросеть, условия Гаусса-Маркова.*

## 1 Введение

Знание того, какое распределение породило признаковое описание выборки или шум в заданных ответах, позволяет обоснованно применять к построенной модели разнообразные критерии математической статистики - мощный аппарат, позволяющий анализировать вероятностные закономерности в данных. Подобный анализ не только помогает интерпретировать модель и улучшать её предсказательные способности, но также позволяет производить отбор признаков по значимости, строить доверительные интервалы, и многое другое. Выборку, для которой известно семейство и параметры распределений, породивших признаковое описание её объектов и, возможно, шум в заданных ответах, назовём простой. На практике, однако, эти распределения часто заранее неизвестны, и изучать их вероятностный характер при необходимости приходится самостоятельно. Именно построение универсального алгоритма, позволяющего установить вероятностный закон, породивший данные, или, другими словами, алгоритма, исследующего выборку на простоту, и становится целью исследования.

Одно из ключевых применений искомого алгоритма находит своё место в совершенствовании нейронных сетей. Как известно, часто результат работы нейронной сети можно рассмотреть как применение некоторой обобщенно-линейной модели к выходам предпоследнего слоя. Совокупность слоев нейронной сети, вплоть до предпоследнего, можно в такой интерпретации рассматривать как композицию в общем случае нелинейных преобразований признакового описания исходной выборки. В итоге на предпоследнем слое сети формируется преобразованная выборка, которая исследуется на простоту с помощью построенного инструмента. Результаты этого исследования помогут усовершенствовать имеющуюся сеть, к примеру, с помощью отбора признаков по значимости окажется возможным предложить технику прореживания сети без потери качества, что является актуальной задачей глубокого обучения.

Как уже упоминалось выше, проводимое исследование существенно опирается на теорию и приложения математической статистики. В первую очередь рассматриваются такие статистические критерии, как критерий Вальда, тест Уайта, тесты Голдфелда-Кванта и

---

\*Научный руководитель: Стрижов В. В. Задачу поставил: Грабовой А. В. Консультант: Гадаев Т. Т.

Дарби-Ватсона, тесты хи-квадрат, Жарка-Бера и Шапиро-Уилка. На основе этих критериев в применении к различным выборкам и вырабатывается искомый алгоритм. Вычислительный эксперимент проводится на наборе стандартных выборок, а также на синтетических и реальных данных.

В качестве основных источников исследованию послужат такие фундаментальные публикации, как [1], ..., а также следующие статьи: ... .

## 2 Постановка задачи

Пусть  $\mathbf{X} \in \mathbb{R}^{m \times n}$  - признаковое описание заданной обучающей выборки с вектором ответов  $\mathbf{y} \in \mathbb{R}^m$ . Пусть также имеется исходная модель - полносвязная нейронная сеть-перцептрон

$$f(\mathbf{x}) = f(\mathbf{x}|\mathbf{w}) : \mathbb{R}^n \rightarrow \mathbb{R},$$

где  $\mathbf{w}$  - совокупность параметров нейронной сети.

В самом общем виде нейронную сеть можно представить в виде последовательности преобразований вида

$$f_i(\mathbf{z}) : \mathbb{R}^{k_{i-1}} \rightarrow \mathbb{R}^{k_i}, f_i(\mathbf{z}) = \mathbf{r}_i(\mathbf{W}_i \times \mathbf{z} + \mathbf{b}_i)$$

- преобразования во внутренних слоях сети, где  $i = 1, \dots, s-1$  ( $s$  - количество слоев нейронной сети),  $\mathbf{W}_i \in \mathbb{R}^{k_i \times k_{i-1}}$  - матрица весов  $i$ -ого слоя,  $\mathbf{b}_i \in \mathbb{R}^{k_i}$  - вектор порогов активации  $i$ -ого слоя,  $\mathbf{r}_i : \mathbb{R}^{k_i} \rightarrow \mathbb{R}^{k_i}$  - функция активации  $i$ -ого слоя ( $k_0 = n$ ).

Завершает цепочку преобразований функция активации последнего слоя, представляющая собой (в простейшем случае) линейную модель над выходами предпоследнего слоя:

$$f_s(\mathbf{z}) : \mathbb{R}^{k_{s-1}} \rightarrow \mathbb{R}, f_s(\mathbf{z}) = \langle \mathbf{w}_s, \mathbf{z} \rangle + b_s,$$

где  $\mathbf{w}_s \in \mathbb{R}^{k_{s-1}}$  - вектор весов, а  $b_s \in \mathbb{R}$  - свободный член линейной модели последнего слоя.

Итого, результат действия нейронной сети на объект представляется в виде композиции:

$$f(\mathbf{x}) = (f_s \circ f_{s-1} \circ \dots \circ f_2 \circ f_1)(\mathbf{x}) = f_s((f_{s-1} \circ \dots \circ f_2 \circ f_1)(\mathbf{x})) = g(h(\mathbf{x})) = (g \circ h)(\mathbf{x}),$$

где  $g = f_s, g(\mathbf{x}) : \mathbb{R}^l \rightarrow \mathbb{R}$  (здесь  $l := k_{s-1}$ ),  $h = f_{s-1} \circ \dots \circ f_2 \circ f_1, h(\mathbf{x}) : \mathbb{R}^n \rightarrow \mathbb{R}^l$ .

Рассмотрим теперь  $\mathbf{Z} = [h(\mathbf{x}_1)^\top, \dots, h(\mathbf{x}_m)^\top]^\top \in \mathbb{R}^{m \times l}$  - совокупность преобразованных внутренними слоями сети исходных векторов признаков, или, другими словами, преобразованное сетью признаковое описание заданной обучающей выборки. Результат действия исходной модели  $f(\mathbf{x})$  на объект  $\mathbf{x}_i \in \mathbf{X}$  эквивалентен результату действия последнего слоя сети, т.е. линейной модели  $g(\mathbf{z}) = \langle \mathbf{w}_s, \mathbf{z} \rangle + b_s$ , на преобразованный объект  $\mathbf{z}_i = h(\mathbf{x}_i) \in \mathbf{Z}$ .

Итак, обратимся теперь к исследованию вышеупомянутой модели  $g(\mathbf{z})$  применительно к выборке  $\mathcal{D} = \{(\mathbf{z}_i, y_i) \mid \mathbf{z}_i = h(\mathbf{x}_i), \mathbf{x}_i \in X, i = 1, \dots, m\}$ . В первую очередь имеющаяся модель исследуется на удовлетворение условиям Гаусса-Маркова. Сформулируем их в виде следующей теоремы:

**Теорема 1.** *Рассматривается модель регрессии, в которой наблюдения  $\mathbf{Y}$  связаны с  $\mathbf{X}$  следующей зависимостью:  $\mathbf{Y}_i = \beta_1 + \langle \beta_2, \mathbf{X}_i \rangle + \varepsilon_i$ . На основе  $n$  выборочных наблюдений оценивается уравнение регрессии  $\hat{\mathbf{Y}}_i = \hat{\beta}_1 + \langle \hat{\beta}_2, \mathbf{X}_i \rangle$ . Теорема Гаусса—Маркова гласит:*

*Если данные обладают следующими свойствами:*

- Модель данных правильно специфицирована;

- Все  $\mathbf{X}_i$  детерминированы и не все равны между собой;
  - Ошибки не носят систематического характера, то есть  $\mathbb{E}(\varepsilon_i) = 0 \forall i$ ;
  - Дисперсия ошибок одинакова и равна некоторой  $\sigma^2$ ;
  - Ошибки некоррелированы, то есть  $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0 \forall i, j$ ;
- то в этих условиях оценки метода наименьших квадратов оптимальны в классе линейных несмещённых оценок.

В случае, когда модель  $g(\mathbf{z})$  с выборкой  $\mathbf{Z}$  не удовлетворяет условиям Гаусса-Маркова, предлагается усовершенствовать исходную сеть, модифицировав параметры её внутренних слоев и получив, таким образом, новую функцию  $h'(\mathbf{x})$ , такую, что преобразованная выборка  $h'(\mathbf{X})$  была простой, а линейная модель уже удовлетворяла бы условиям Гаусса-Маркова. Эта функция также должна быть выбрана из следующих соображений: имеющаяся новая модель - модифицированная нейронная сеть  $f'(\mathbf{x}) = g(h'(\mathbf{x}))$  должна иметь меньшую среднеквадратичную ошибку на тестовой выборке (предполагая разделение исходной выборки на обучение и тест). Другими словами, ищется такая модификация  $h'$ , что

$$Q(\mathbf{X}|f') \leq Q(\mathbf{X}|f),$$

где  $Q(\mathbf{X}|f) = \frac{1}{m} \sum_{j=1}^m (f(\mathbf{x}_m) - \mathbf{y}_m)^2$  - среднеквадратичная ошибка алгоритма на выборке. Поиску такой функции  $h'$  будет посвящен следующий раздел.

## Литература

- [1] Christopher M. Bishop. *Pattern recognition and machine learning, 5th Edition*. Information science and statistics. Springer, 2007.

*Поступила в редакцию*